



Projecto de 1ª época

Introdução

Após a conclusão do seu mestrado em ciência dos dados, foi contratado pela empresa `Dados Complicados` para uma posição de “*Engenheiro de Dados Júnior*”.

Como primeiro trabalho, foi integrado num projecto de data science relacionado com a Educação, sendo o cliente a infame `Universidade do País das Maravilhas`. Neste âmbito, o *Cientista de Dados (CdD)* atribuiu-lhe a produção de uma primeira versão de uma *dataframe* que ele irá usar para começar a fazer análise exploratória dos dados. Dado o seu estatuto de junior, o *CdD* (que é sabido), teve o cuidado de avisar de que podem haver erros nos dados e pede para que isso seja tido em conta.

Foi-lhe enviado um email com a seguinte descrição da realidade:

Colega,

Conforme discutimos em pessoa, vou precisar que me seja produzida uma *dataframe* para que depois eu possa fazer algumas análises de correlações.

Os dados são relativos a alunos de uma Universidade.

Neste momento temos um ficheiro .sql com um dump dos dados da BD do cliente e um CSV com dados complementares.

Relativamente ao SQL, só nos foi enviado o conteúdo de uma da tabela: a tabela “aluno”. Parece-me que a tabela não está normalizada, mas adiante. Não nos enviaram informação sobre a estrutura da tabela, por isso vai ser preciso fazer *reverse engineering* da mesma.

A tabela é suposto conter dados sobre os alunos de três licenciaturas:

- Informática
- Psicologia
- Comunicação

Em relação ao CSV com dados complementares, não recebemos qualquer informação, por isso é preciso perceber como é que as coisas se vão ligar.

Preciso disto processado até ao dia **(domingo imediatamente a seguir à última aula).**

Se existirem problemas nos dados, tenho de ser avisado o mais cedo possível, para poder validar com a Professora Alice, que é o nosso contacto no cliente.

Obrigado e bom trabalho!

Objectivo do trabalho

O objectivo principal deste trabalho é fazer chegar dados de qualidade ao *Cientista de Dados*, a partir de uma ou mais fontes de dados.

Esta é a tarefa típica de “Engenharia de Dados”, tal como apresentada na primeira aula desta unidade curricular.

Estrutura do trabalho

O trabalho está dividido em duas fases que se complementam.

A primeira fase foca-se em dados que deverão ser obtidos directa e exclusivamente a partir de uma base de dados relacional.

A segunda fase foca-se na conjugação de múltiplas fontes de dados: parte dos dados virão de uma base de dados relacional, enquanto que os restantes dados virão de um ficheiro CSV.

[Primeira fase]

Para começar o trabalho, o *Cientista de Dados* quer-se dedicar à seguinte pergunta:

- Existe alguma relação entre a média de entrada na licenciatura e a média de conclusão da licenciatura?

[Segunda fase]

Numa segunda fase, o *Cientista de Dados* pretende-se dedicar a mais uma pergunta:

- Existe alguma relação entre a origem dos alunos (curso profissional ou curso do ensino geral) e a média final da licenciatura?

Infelizmente, a *Universidade do País das Maravilhas* não tem um registo centralizado desses dados, estando os mesmos apenas disponíveis num ficheiro CSV. Para além disso, esses dados apenas existem para um sub-conjunto dos alunos. Os alunos para

Universidade Lusófona de Humanidades e Tecnologias
Mestrados em Ciência de Dados / Mestrado em Engenharia Informática e Sistemas de
Informação
Tópicos em Engenharia de Dados
2025/2026
Bruno Cipriano
v1.0.0

os quais esta informação não exista devem ser ignorados, mas não constituem situações de erro.

Nota: o ficheiro de dados da segunda fase apenas será distribuído aos alunos quando o Professor considerar que o trabalho da primeira fase está satisfatório.

Dados de input

O projecto deverá ser desenvolvido com base em dois ficheiros:

Ficheiro	Descrição	Fases
dados_alunos.sql	Contém queries SQL de “insert” que permitem replicar o conteúdo da base de dados da Universidade do País das Maravilhas.	1 e 2
dados_origem_alunos.csv	Ficheiro CSV que contém a origem de cada aluno.	2

Notas:

- Os ficheiros de input podem conter dados inválidos.
- O aluno terá de reflectir sobre os dados de forma a identificar situações que considere suspeitas. Essas situações devem ser discutidas com o professor, de forma a chegar a um acordo sobre o que o aluno deverá considerar válido ou inválido.


Tarefas do Engenheiro de dados Júnior
--

Espera-se que o engenheiro de dados júnior (o aluno) execute o seguinte conjunto de tarefas:

1. Análise do ficheiro dados_alunos.sql de forma a perceber qual a estrutura necessária para a BD.
 - Criação dessa BD (usando, p.e., o PHPMyAdmin)
 - Importação do ficheiro SQL para essa Base de Dados.
2. Analisar os dados, de forma a encontrar dados inválidos, suspeitos e/ou estranhos.
 - Vejam a secção de “Dicas” mais abaixo neste enunciado.
3. **Validar os dados inválidos, suspeitos e/ou estranhos ou com o Professor.**
 - Não serão aceites projectos que não tenham passado por esta fase de validação de regras por parte do professor.
4. Extracção dos dados relevantes da base de dados para um ficheiro CSV.
 - Usando código Python
 - Deve ser criado um ficheiro CSV para cada “fase” do trabalho
 - Exemplo: fase1.csv e fase2.csv
5. O ficheiro CSV produzido (p.e. fase1.csv) não deve ter dados inválidos ou inesperados.
 - Por essa razão, o engenheiro de dados tem de arranjar uma forma programática (usando código Python e/ou SQL) de excluir os dados inválidos do ficheiro CSV.
6. Produção de forma programática (usando código Python e/ou SQL) de um ficheiro .txt com informação que permita identificar dados considerados inválidos, para que possam ser investigados mais tarde.
 - Estes dados devem estar ordenados por número de aluno.
 - Deve ser criado um ficheiro CSV para cada “fase” do trabalho
7. Criação de (pelo menos) um notebook Jupyter que consiga carregar o(s) ficheiro(s) CSV produzido(s).
8. Execução de alguma Exploratory Data Analysis (EDA)
 - O âmbito da EDA fica a cargo dos alunos.
 - No entanto, sugere-se que calculem pelo menos as estatísticas descritivas e que tentem responder à “pergunta” de cada fase.

9. Implementação de 2 requisitos extra, acordados com o Professor durante o desenvolvimento do trabalho.
10. Produzir um Relatório que explique:
- dificuldades
 - problemas encontrados (p.e. erros nos dados) e explicação de como foram descobertos e ultrapassados
 - resultado da EDA
 - encontraram alguma coisa de interessante nos dados?
 - como é que lá chegaram?
 - o formato do relatório fica ao critério dos alunos
 - (pode ser um PDF, um PPT, um vídeo *unlisted* no youtube, etc.)

Diagrama ilustrativo (fase 1)



Nota:

- o Jupyter aparece neste diagrama apenas no final, mas podem usar o Jupyter em qualquer etapa do processo (nomeadamente na parte de dividir entre “registos válidos” e registos inválidos).

[Restrições técnicas]

Os alunos não podem alterar os dados da base de dados (ficheiro .SQL fornecido).

Os ficheiros CSV e txt a produzir têm de ser produzidos por código Python.

O código entregue pelos alunos tem de compilar e tem de produzir ficheiros CSV e txt com os mesmos conteúdos que os ficheiros entregues pelos alunos.

Avaliação

Serão avaliados quer aspectos técnicos (por exemplo, a correcção dos ficheiros de código produzidos), quer comportamentais (por exemplo, interacção com o professor).

Existirá uma defesa do projecto, durante a qual cada aluno terá de fazer alterações ao código do seu projecto, de forma a mostrar conhecimento e domínio do mesmo. Dessa defesa sairá uma nota em percentagem (0-100), que será depois aplicada à nota base do projecto de forma a calcular a nota de projecto do aluno. Por exemplo, um aluno que tenha nota base igual a 18 valores e 50% na defesa, terá como nota do projecto 9 valores.

[Dicas]

Como identificar dados “inválidos”?

- Pensem nos valores esperados para cada coluna, considerando:
 - o nome da coluna;
 - o tipo de dados da coluna;
 - o objectivo da coluna no contexto da tabela.
- Usando o PHPMyAdmin, escolham sub-conjuntos arbitrários dos dados e vejam se encontram alguma coisa “estranha” considerando o enunciado e o “domínio” de negócio (educação).
- Façam verificações sistemáticas das várias colunas
 - Por exemplo, procurem em cada coluna:
 - valores null
 - valores duplicados
 - etc

- Devem **sempre** confirmar eventuais “suspeitas” com o Professor.

Como filtrar os inválidos?

- Existem várias estratégias possíveis:
 - Podemos fazer uma query SQL única que vai buscar tudo à base de dados e depois ter código Python que identifica os inválidos e os coloca “de parte” usando instruções condicionais (p.e. usando IFs).
 - Podemos fazer uma query SQL que vai buscar os dados válidos (para fazer um determinado tratamento) e depois fazer outra query SQL que vai buscar os dados inválidos (para fazer outro tratamento).
 - ...

[Como entregar o projecto]

Os alunos devem criar um repositório **privado** no GitHub. Esse repositório deverá ser partilhado com o professor (username: brunompc) até ao final do dia **24/Abril/2025**.

Todo o código que os alunos produzam para o projecto (Python, SQL, etc.) deverá ser colocado nesse repositório.

Os ficheiros (CSV, txt) **gerados** pelo código dos alunos também deverão ser colocados no mesmo repositório.

Os ficheiros presentes no repositório devem ter nomes auto-explicativos e representativos do seu conteúdo.

O prazo de entrega do projecto é o **domingo imediatamente a seguir à última aula desta disciplina, às 23h59m (hora de Lisboa)**.

Para facilitar a avaliação, os alunos não devem fazer commits após esse dia e hora.

Outras informações relevantes

- O projecto deverá ser realizado individualmente.
- Casos de plágio ou outro tipo de fraude académica levarão à reprovação do aluno na unidade curricular.
 - A decisão sobre se um projecto constitui um caso de fraude cabe exclusivamente ao docente da UC.
- Eventuais erros no enunciado e/ou nos dados serão comunicados por mensagem no fórum do moodle.
- Eventuais situações omissas serão resolvidas, caso-a-caso, pelo docente da UC.

FIM